

Técnicas de Amostragem - Simulação

Gabriella de Oliveira Argenton 255677 Gabriela Namie Hidaka 204274 Pedro Montei

```
set.seed(123)

#### 1) Gerar uma população "oculta" com heterogeneidade ####

N <- 5000 # tamanho da população

# "Conectividade" dos indivíduos (análoga ao b_j do modelo de Rasch)
b <- rnorm(N, mean = 0, sd = 1)

# Variável de interesse Y (ex: número de clientes, gasto, etc.)
# Aqui fazemos Y correlacionada com b, só para ficar mais realista
Y <- 10 + 2*b + rnorm(N, mean = 0, sd = 3)

# Verdadeira média populacional (para comparar depois)
mu_true <- mean(Y)
mu_true
```

```
[1] 9.986339
```

```
#### 2) Definir probabilidades de inclusão heterogêneas ####

# Parâmetros da "função logística" (simplificação do Rasch)
alpha <- -2 # nível geral de inclusão
beta <- 1 # quanto a conectividade b_j influencia a inclusão

# Probabilidade de inclusão de cada indivíduo
pi_vec <- 1 / (1 + exp(-(alpha + beta * b)))

summary(pi_vec) # só pra ver a distribuição das probabilidades
```

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
	0.005839	0.065673	0.118410	0.154968	0.207672	0.809381

```
mean(pi_vec) * N      # tamanho médio de amostra esperado
```

```
[1] 774.8422
```

```
#### 3) Desenhar UMA amostra da população ####
```

```
# Cada indivíduo entra na amostra com probabilidade pi_j (amostragem Bernoulli)
S <- rbinom(N, size = 1, prob = pi_vec) # 1 = na amostra, 0 = fora
sum(S)                                # tamanho da amostra obtida
```

```
[1] 773
```

```
Y_s <- Y[S == 1]
pi_s <- pi_vec[S == 1]

length(Y_s)
```

```
[1] 773
```

```
#### 4) Três estimadores da média ####
```

```
# 1) Média ingênua (sem pesos)
mean_naive <- mean(Y_s)

# 2) Estimador tipo Horvitz-Thompson para o total
T_HT <- sum(Y_s / pi_s)
N_hat_HT <- sum(1 / pi_s) # estimativa de N (só pra referência)
mu_HT <- T_HT / N          # se N é conhecido
# ou mu_HT <- T_HT / N_hat_HT se você quiser também ilustrar com N estimado

# 3) Estimador tipo Hájek para a média
mu_Hajek <- sum(Y_s / pi_s) / sum(1 / pi_s)

c(mu_true = mu_true,
  naive   = mean_naive,
  HT      = mu_HT,
  Hajek   = mu_Hajek)
```

mu_true	naive	HT	Hajek
9.986339	11.454791	9.845307	9.954740

```
#### 5) Bootstrap para o estimador de Hájek ####
```

```
B <- 1000 # número de réplicas bootstrap
```

```
mu_Hajek_boot <- numeric(B)
```

```
for (b_rep in 1:B) {
```

```
  # reamostragem com reposição DENTRO da amostra obtida
```

```
  idx <- sample(seq_along(Y_s), size = length(Y_s), replace = TRUE)
```

```
  Y_b <- Y_s[idx]
```

```
  pi_b <- pi_s[idx]
```

```
  mu_Hajek_boot[b_rep] <- sum(Y_b / pi_b) / sum(1 / pi_b)
```

```
}
```

```
# Erro-padrão bootstrap
```

```
se_boot <- sd(mu_Hajek_boot)
```

```
# Intervalo de confiança normal aproximado
```

```
alpha_ci <- 0.05
```

```
z <- qnorm(1 - alpha_ci/2)
```

```
IC_lower <- mu_Hajek - z * se_boot
```

```
IC_upper <- mu_Hajek + z * se_boot
```

```
c(mu_true = mu_true,
```

```
  mu_Hajek = mu_Hajek,
```

```
  IC_lower = IC_lower,
```

```
  IC_upper = IC_upper)
```

```
mu_true mu_Hajek IC_lower IC_upper
9.986339 9.954740 9.561835 10.347644
```

```
hist(mu_Hajek_boot,
```

```
  main = "Distribuição bootstrap do estimador de Hájek",
```

```
  xlab = "Média estimada (Hájek)",
```

```
  breaks = 30)
```

```
abline(v = mu_true, col = "red", lwd = 2) # verdadeira média populacional
```

```
abline(v = mu_Hajek, col = "blue", lwd = 2) # estimativa observada
```

Distribuição bootstrap do estimador de Hájek

